



Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México

Análisis y Reporte sobre el desempeño del modelo

TC3006C. Inteligencia artificial avanzada para la ciencia de datos I

Grupo: 101

A01749667. Alan Contreras Prieto

Prof. Jorge Adolfo Ramírez Uresti

Fecha de entrega: 10 de septiembre de 2025

Semestre agosto – diciembre 2025

Análisis del desempeño del modelo

Separación de los datos y evaluación del modelo

Para evaluar el desempeño del modelo, el dataset se dividió en dos conjuntos: 80% para entrenamiento: con el fin de que el modelo pueda aprender patrones y relaciones dentro de los datos. 20% para prueba: utilizado exclusivamente para validar el rendimiento y asegurar que el modelo no se limite a memorizar los ejemplos de entrenamiento. Esta proporción es una práctica común en problemas de aprendizaje automático, pues ofrece un equilibrio entre disponer de un volumen amplio de datos para entrenar y conservar una muestra representativa para medir la capacidad de generalización del modelo.

La evaluación del desempeño se llevó a cabo mediante el uso de la matriz de confusión y de métricas fundamentales de clasificación, tales como accuracy, precision, recall y F1-score, obteniendo como resultado un accuracy general de 0.83, lo que refleja un rendimiento sólido y confiable.

Diagnóstico de bias (sesgo)

En cuanto al diagnóstico de bias o sesgo, este concepto hace referencia a los errores que aparecen cuando un modelo realiza suposiciones demasiado simples o cae en generalizaciones excesivas, limitando su capacidad predictiva. En este caso, el uso de un Random Forest resulta especialmente adecuado, ya que este modelo combina múltiples árboles de decisión y, al hacerlo, logra reducir de manera significativa el sesgo característico que suele presentarse en un único árbol.

Por esta razón, el bias se puede diagnosticar como bajo, lo que se evidencia en el nivel de accuracy obtenido y en la distribución equilibrada de resultados entre las clases. Estos indicadores sugieren que el modelo fue capaz de captar las relaciones presentes en los datos sin recurrir a simplificaciones inadecuadas.

Diagnóstico de varianza

Respecto a la varianza, esta se entiende como la sensibilidad del modelo a pequeñas variaciones en los datos de entrenamiento, lo cual, si es elevado, puede conducir al sobreajuste. En el caso de Random Forest, la construcción del modelo a partir de un ensamble de árboles entrenados con subconjuntos aleatorios de datos y características contribuye a mitigar este riesgo, ya que el promedio de las predicciones reduce la inestabilidad inherente a cada árbol individual.

Por esta razón, el nivel de varianza se puede diagnosticar como medio-bajo. Aunque los árboles por separado tienden a mostrar alta varianza, el efecto de agregación característico del Random Forest permite suavizar este comportamiento. El desempeño estable en el conjunto de prueba respalda esta conclusión, confirmando que el modelo no depende en exceso de las particularidades del conjunto de entrenamiento.

Diagnóstico del ajuste del modelo

El ajuste del modelo se analiza comparando los resultados en entrenamiento y prueba:

- Underfitting: ocurre cuando el modelo no logra aprender los patrones de los datos y obtiene un bajo rendimiento tanto en entrenamiento como en prueba.
- Overfitting: ocurre cuando el modelo memoriza los datos de entrenamiento y falla al generalizar, mostrando una gran diferencia de desempeño entre entrenamiento y prueba.
- Fit adecuado: ocurre cuando el modelo logra un equilibrio entre aprendizaje y generalización.

Por lo tanto, el ajuste del modelo se puede diagnosticar como un Fit adecuado. El modelo alcanzó un desempeño consistente y sólido entre el conjunto de entrenamiento y el de prueba, sin diferencias significativas. Los resultados son equilibrados entre todas las clases, lo que confirma que el Random Forest fue capaz de generalizar sin caer en underfitting ni en overfitting.